LAPORAN PENAMBANGAN DATA

Analisis Perbandingan Metode *Clustering* pada *Rice* (Cammeo and Osmancik) Dataset Menggunakan K-Means, Hierarchical Clustering, DBSCAN, dan Fuzzy C-Means untuk Identifikasi Pola Kelompok Beras

Disusun oleh:

Afifah (24031554202)

Dosen Pengampu :

Moh. Khoridatul Huda, S.Pd., M.Si., Ph.D.

PRODI S1 SAINS DATA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS NEGERI SURABAYA

2026

DAFTAR ISI

DAFTAR ISI ..... **ii**

BAB I PENDAHULUAN **4**

1.1 Latar Belakang 4

1.2 Rumusan Masalah 5

1.3 Tujuan Analisis 5

BAB II TINJAUAN PUSTAKA **6**

2.1 Clustering 6

2.2 Metode Clustering yang Digunakan 6

2.3 Evaluasi Clustering 7

BAB III METODOLOGI PENELITIAN **8**

3.1 Sumber Data 8

3.3 Data Preprocessing 9

3.4 Metode Clustering 9

3.5 Evaluasi 10

BAB IV HASIL DAN PEMBAHASAN **12**

4.1 Eksplorasi Data Awal 12

4.2 Preprocessing Data 14

4.3 Hasil Clustering K-Means 15

4.4 Hasil Clustering Hierarchical Clustering 17

4.5 Hasil DBSCAN 19

4.6 Hasil Fuzzy C-Means 21

4.7 Perbandingan Metode Clustering 22

BAB V PENUTUP **24**

5.1 Kesimpulan 24

5.2 Saran 24

DAFTAR PUSTAKA 25

LAMPIRAN 27

Lampiran 1. Kode Program 27

Lampiran 2. Visualisasi 27

Lampiran 3. Tabel 28

BAB I PENDAHULUAN

1.1 Latar Belakang

Perkembangan analisis data saat ini mendorong semakin luasnya penerapan teknik *data mining* dalam mengolah informasi dari berbagai bidang. Salah satu teknik yang banyak digunakan adalah *clustering*, yaitu metode pengelompokan data berdasarkan kemiripan karakteristik tanpa memerlukan label kelas dalam proses pembentukannya [18]. Metode ini termasuk dalam *unsupervised learning* yang berguna ketika struktur alami data belum diketahui sebelumnya.

Berbagai algoritma *clustering* telah dikembangkan dengan karakteristik yang berbeda-beda. K-Means dikenal sebagai algoritma yang sederhana dan efisien dalam memproses data berskala besar [1], sementara *Hierarchical Clustering* mampu menggambarkan hubungan bertingkat antar data melalui visualisasi dendrogram [6]. DBSCAN memiliki keunggulan dalam mendeteksi *noise* dan membentuk *cluster* dengan pola tidak beraturan [11], sedangkan Fuzzy C-Means menawarkan fleksibilitas dengan memungkinkan satu data memiliki derajat keanggotaan pada lebih dari satu cluster sekaligus [12]. Perbedaan karakteristik tersebut menyebabkan masing-masing metode dapat menghasilkan performa yang berbeda pada dataset yang sama, sehingga perbandingan antar metode perlu dilakukan untuk menentukan pendekatan yang paling sesuai.

Penelitian ini menggunakan *Rice (Cammeo and Osmancik) Dataset* yang memuat karakteristik morfologi dua jenis beras. Meskipun dataset ini memiliki label kelas, analisis tetap dilakukan dengan pendekatan *clustering*, yaitu dengan mengabaikan label pada tahap pemodelan. Label kelas kemudian dimanfaatkan pada tahap evaluasi eksternal untuk menilai kesesuaian hasil pengelompokan terhadap kondisi data sesungguhnya [14]. Dataset ini dipilih karena memiliki fitur-fitur numerik yang representatif dan relevan untuk analisis berbasis jarak. Berdasarkan hal tersebut, penelitian ini bertujuan membandingkan metode K-Means, Hierarchical Clustering, DBSCAN, dan Fuzzy C-Means dalam mengidentifikasi pola kelompok pada data beras serta menentukan metode terbaik berdasarkan evaluasi internal menggunakan Silhouette Score [15]. Hasil analisis diharapkan dapat memberikan gambaran mengenai performa masing-masing metode *clustering*.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana struktur alami data pada *Rice (Cammeo and Osmancik) Dataset* jika dianalisis menggunakan metode clustering?
2. Berapa jumlah cluster yang optimal untuk merepresentasikan pola kelompok pada dataset tersebut?
3. Bagaimana hasil pengelompokan data menggunakan metode K-Means, Hierarchical Clustering, DBSCAN, dan Fuzzy C-Means?
4. Metode clustering mana yang memberikan performa terbaik berdasarkan evaluasi menggunakan *Silhouette Score*?
5. Sejauh mana hasil clustering sesuai dengan label asli data (Cammeo dan Osmancik)?

1.3 Tujuan Analisis

Berdasarkan rumusan masalah yang telah disusun, tujuan dari penelitian ini adalah sebagai berikut:

1. Menentukan jumlah cluster yang optimal untuk merepresentasikan pola kelompok dalam data.
2. Menerapkan dan membandingkan metode K-Means, Hierarchical Clustering, DBSCAN, dan Fuzzy C-Means dalam proses pengelompokan data.
3. Mengevaluasi performa masing-masing metode clustering menggunakan *Silhouette Score*.
4. Menganalisis kesesuaian hasil clustering dengan label asli data untuk menilai kualitas pengelompokan yang dihasilkan.

BAB II TINJAUAN PUSTAKA

2.1 Clustering

Clustering merupakan teknik dalam *data mining* yang digunakan untuk mengelompokkan data berdasarkan kemiripan karakteristik antar objek tanpa memerlukan label kelas, sehingga termasuk dalam *unsupervised learning* [18]. Tujuan utamanya adalah membentuk kelompok dengan kemiripan tinggi di dalam cluster (*intra-cluster similarity*) dan perbedaan besar antar cluster (*inter-cluster dissimilarity*). Beberapa metode *clustering* yang biasa digunakan antara lain *partition-based* (K-Means), *hierarchical*, *density-based* (DBSCAN), dan *fuzzy clustering* (Fuzzy C-Means) [5]. Setiap metode memiliki karakteristik dan keterbatasan masing-masing, sehingga pemilihan metode perlu disesuaikan dengan karakteristik dataset untuk menghasilkan pengelompokan yang optimal.

2.2 Metode Clustering yang Digunakan

1. K-Means Clustering

   K-Means merupakan metode *partition-based clustering* yang bekerja dengan membagi data ke dalam sejumlah cluster berdasarkan jarak setiap objek terhadap pusat *cluster* (*centroid*) [1]. Proses pembentukan *cluster* dilakukan secara iteratif dengan memperbarui posisi centroid hingga kondisi konvergen tercapai. Metode ini dikenal sederhana dan efisien, namun memiliki kelemahan berupa sensitivitas terhadap jumlah cluster yang harus ditentukan sejak awal dan rentan terhadap keberadaan outlier [3].

2. Hierarchical Clustering

   Hierarchical Clustering adalah metode yang membentuk struktur *cluster* secara bertingkat dan divisualisasikan dalam bentuk dendrogram [6]. Terdapat dua metode utama, yaitu *agglomerative* yang menggabungkan cluster dari bawah ke atas dan *divisive* yang memecah cluster dari atas ke bawah. Kelebihan metode ini adalah tidak memerlukan penentuan jumlah cluster di awal, meskipun cenderung lebih kompleks dan sensitif terhadap pemilihan ukuran jarak dan metode penggabungan yang digunakan [7].

3. DBSCAN

   DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) merupakan metode *density-based clustering* yang mengelompokkan data berdasarkan

kepadatan titik dalam suatu area tertentu [11]. Metode ini dapat mendeteksi *cluster* dengan bentuk tidak beraturan sekaligus mengidentifikasi noise. Berbeda dengan K-Means, DBSCAN tidak memerlukan jumlah *cluster* di awal, namun performanya sangat bergantung pada penentuan parameter epsilon (ε) dan *minimum points* (MinPts) yang tepat [10].

4. Fuzzy C-Means

   Fuzzy C-Means (FCM) merupakan metode clustering berbasis *fuzzy logic* di mana setiap data tidak hanya masuk ke satu cluster secara mutlak, melainkan memiliki derajat keanggotaan tertentu pada setiap *cluster* [12]. Metode ini memungkinkan model menangani data dengan karakteristik tumpang tindih (*overlap*) antar cluster sehingga hasil pengelompokan lebih fleksibel dibandingkan metode *hard clustering*. Meski demikian, FCM tetap memerlukan penentuan jumlah cluster dan parameter *fuzziness* sejak awal [13].

2.3 Evaluasi Clustering

Evaluasi *clustering* dilakukan untuk menilai kualitas hasil pengelompokan yang dihasilkan oleh suatu metode. Secara umum, evaluasi *clustering* dibagi menjadi dua jenis, yaitu evaluasi internal dan evaluasi eksternal [14]. Evaluasi internal mengukur kualitas cluster berdasarkan struktur data itu sendiri tanpa melibatkan label asli, sedangkan evaluasi eksternal menilai hasil *clustering* dengan membandingkannya terhadap label kelas yang telah diketahui sebelumnya.

Salah satu metrik evaluasi internal yang paling umum digunakan adalah *Silhouette Score* [15]. Metrik ini mengukur seberapa baik suatu objek data berada dalam clusternya sendiri dibandingkan dengan cluster lain yang berdekatan. Nilai *Silhouette Score* berkisar antara -1 hingga 1, di mana nilai mendekati 1 menunjukkan bahwa data telah berada pada cluster yang tepat dan terpisah dengan baik, nilai mendekati 0 mengindikasikan adanya tumpang tindih (*overlap*) antar cluster, sedangkan nilai negatif menunjukkan kemungkinan kesalahan pengelompokan [16]. Dengan demikian, semakin tinggi nilai *Silhouette Score* yang diperoleh, semakin baik kualitas clustering yang dihasilkan oleh suatu metode.

BAB III METODOLOGI PENELITIAN

3.1 Sumber Data

Dataset yang digunakan dalam analisis ini adalah *Rice (Cammeo and Osmancik) Dataset* yang diperoleh dari UCI Machine Learning Repository [19]. Dataset ini terdiri dari 3.810 observasi dengan 8 variabel, yang mencakup 7 fitur numerik dan 1 variabel label. Fitur numerik yang digunakan meliputi *Area*, *Perimeter*, *Major Axis Length*, *Minor Axis Length*, *Eccentricity*, *Convex Area*, dan *Extent*, yang secara keseluruhan merepresentasikan karakteristik morfologi butiran beras.

Variabel label dalam dataset menunjukkan dua jenis beras, yaitu Cammeo sebanyak 1.630 observasi dan Osmancik sebanyak 2.180 observasi. Meskipun label kelas tersedia, label tidak dilibatkan dalam proses pembentukan cluster karena menggunakan *unsupervised learning* [18]. Label hanya digunakan pada tahap evaluasi eksternal, yaitu untuk membandingkan hasil pengelompokan dengan kondisi kelas yang sebenarnya.

3.2 Tahapan Analisis

Tahapan analisis dilakukan untuk memastikan proses *clustering* berjalan dengan baik dan menghasilkan kesimpulan yang valid. Adapun langkah-langkah yang dilakukan adalah sebagai berikut.

1. Pengumpulan Data

   Dataset *Rice (Cammeo and Osmancik)* diperoleh dari UCI Machine Learning Repository [19] sebagai objek utama penelitian.
2. Eksplorasi Data Awal

   Dilakukan analisis deskriptif untuk memahami karakteristik dataset, meliputi distribusi setiap variabel, sebaran kelas, dan identifikasi outlier.
3. Preprocessing Data

   Data dipersiapkan melalui pengecekan *missing value* dan data duplikat, kemudian dilakukan standardisasi menggunakan metode Z-score agar seluruh variabel berada pada skala yang seragam sebelum proses *clustering* dilakukan [17].
4. Clustering

   Diterapkan empat metode *clustering*, yaitu K-Means, Hierarchical Clustering,

DBSCAN, dan Fuzzy C-Means untuk mengelompokkan data berdasarkan kemiripan karakteristik morfologi beras [5].

5. Evaluasi Hasil Clustering

   Kualitas hasil pengelompokan dievaluasi menggunakan *Silhouette Score* sebagai evaluasi internal [15], dan dibandingkan dengan hasil cluster dengan label kelas asli sebagai evaluasi eksternal [14].

6. Perbandingan Metode

   Hasil dari keempat metode clustering dibandingkan untuk menentukan metode yang paling optimal berdasarkan performa pengelompokan yang dihasilkan.

3.3 Data Preprocessing

Tahap *preprocessing* dilakukan untuk memastikan kualitas data sebelum proses *clustering* dilaksanakan, sehingga hasil yang diperoleh lebih akurat dan dapat diandalkan [17]. Langkah pertama adalah pengecekan *missing value* untuk memastikan tidak terdapat data yang hilang dalam dataset. Selanjutnya dilakukan pengecekan duplikasi data guna menghindari pengulangan observasi yang dapat memengaruhi hasil analisis.

Setelah data dinyatakan bersih, dilakukan standardisasi menggunakan metode Z-score untuk menyeragamkan skala antar variabel. Standardisasi ini penting dilakukan karena metode clustering berbasis jarak seperti K-Means dan Hierarchical Clustering sangat sensitif terhadap perbedaan skala antar variabel [3][7]. Selain itu, dilakukan visualisasi awal menggunakan *boxplot* untuk mendeteksi keberadaan outlier yang berpotensi memengaruhi pembentukan cluster. Dengan tahapan *preprocessing* yang tepat, data menjadi lebih siap untuk dianalisis pada tahap clustering selanjutnya.

3.4 Metode Clustering

Pada tahap ini diterapkan empat metode *clustering* untuk mengelompokkan data berdasarkan kemiripan karakteristik morfologi beras. Metode yang digunakan meliputi K-Means Clustering, Hierarchical Clustering, DBSCAN, dan Fuzzy C-Means [5].

1. K-Means Clustering

   K-Means digunakan untuk membagi data ke dalam sejumlah cluster yang ditentukan sebelumnya [1]. Proses dimulai dengan inisialisasi centroid, kemudian setiap

data dikelompokkan ke centroid terdekat, dan posisi centroid diperbarui secara iteratif hingga kondisi konvergen tercapai. Jumlah *cluster* optimal ditentukan menggunakan *Elbow Method* berdasarkan nilai *Within-Cluster Sum of Squares* (WSS) [2].

2. Hierarchical Clustering

   Hierarchical Clustering dilakukan dengan metode *agglomerative*, yaitu menggabungkan data secara bertahap berdasarkan jarak terdekat hingga membentuk struktur pohon yang divisualisasikan dalam bentuk dendrogram [6]. Proses penggabungan diawali dengan menghitung jarak antar seluruh data, kemudian pasangan data dengan jarak terkecil digabungkan terlebih dahulu. Jumlah *cluster* ditentukan dengan memotong dendrogram pada level ketinggian tertentu [7].

3. DBSCAN

   DBSCAN mengelompokkan data berdasarkan kepadatan titik dengan dua parameter utama, yaitu epsilon (ε) dan *minimum points* (MinPts) [11]. Nilai epsilon ditentukan melalui analisis grafik jarak *k-nearest neighbor* (KNN), sedangkan nilai MinPts ditentukan berdasarkan jumlah variabel yang digunakan ditambah satu [10]. Metode ini dapat mendeteksi noise dan membentuk *cluster* dengan bentuk yang tidak beraturan.

4. Fuzzy C-Means

   Fuzzy C-Means merupakan metode clustering yang memberikan derajat keanggotaan pada setiap data terhadap masing-masing *cluster* dengan nilai berkisar antara 0 hingga 1 [12]. Berbeda dengan metode *hard clustering*, FCM memungkinkan satu data menjadi bagian dari lebih dari satu cluster secara bersamaan sesuai tingkat keanggotaannya [13]. Pada analisis ini, hasil FCM dianalisis baik dari sisi pembagian cluster maupun distribusi nilai keanggotaan (*membership degree*).

3.5 Evaluasi

Evaluasi dilakukan untuk menilai kualitas hasil *clustering* yang dihasilkan oleh masing-masing metode. Pada analisis ini, evaluasi menggunakan dua pendekatan, yaitu evaluasi internal dan evaluasi eksternal [14].

1. Evaluasi Internal (Silhouette Score)

   Evaluasi internal dilakukan menggunakan *Silhouette Score* untuk mengukur

kualitas struktur *cluster* yang terbentuk [15]. Metrik ini menilai seberapa dekat suatu data terhadap clusternya sendiri dibandingkan dengan cluster lain yang berdekatan. Nilai *Silhouette Score* berada pada rentang -1 hingga 1, di mana nilai mendekati 1 menunjukkan bahwa data telah terkelompok dengan baik dan terpisah secara jelas, nilai mendekati 0 mengindikasikan adanya tumpang tindih (*overlap*) antar cluster, sedangkan nilai negatif menunjukkan kemungkinan kesalahan pengelompokan [16]. Semakin tinggi nilai *Silhouette Score* yang diperoleh, semakin baik kualitas clustering yang dihasilkan.

2. Evaluasi Eksternal (Perbandingan dengan Label Asli)

   Evaluasi eksternal dilakukan dengan membandingkan hasil *cluster* yang terbentuk pada label kelas asli dataset, yaitu Cammeo dan Osmancik [14]. Meskipun label tidak dilibatkan dalam proses *clustering*, perbandingan ini memberikan gambaran sejauh mana setiap metode mampu merepresentasikan struktur sebenarnya dari data.

BAB IV HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data Awal

Tahap eksplorasi data awal dilakukan untuk memahami karakteristik dataset sebelum proses clustering dilaksanakan. Analisis diawali dengan pemeriksaan statistik deskriptif pada setiap variabel, mencakup nilai rata-rata, median, standar deviasi, serta nilai minimum dan maksimum.

```
      Area          Perimeter      Major_Axis_Length Minor_Axis_Length  Eccentricity      Convex_Area
 Min.   : 7551   Min.   :359.1   Min.   :145.3     Min.   : 59.53    Min.   :0.7772   Min.   : 7723
 1st Qu.:11370   1st Qu.:426.1   1st Qu.:174.4     1st Qu.: 82.73    1st Qu.:0.8724   1st Qu.:11626
 Median :12422   Median :448.9   Median :185.8     Median : 86.43    Median :0.8891   Median :12706
 Mean   :12668   Mean   :454.2   Mean   :188.8     Mean   : 86.31    Mean   :0.8869   Mean   :12952
 3rd Qu.:13950   3rd Qu.:483.7   3rd Qu.:203.6     3rd Qu.: 90.14    3rd Qu.:0.9026   3rd Qu.:14284
 Max.   :18913   Max.   :548.4   Max.   :239.0     Max.   :107.54    Max.   :0.9480   Max.   :19099
     Extent          Class
 Min.   :0.4974   Length:3810
 1st Qu.:0.5989   Class :character
 Median :0.6454   Mode  :character
 Mean   :0.6619
 3rd Qu.:0.7266
 Max.   :0.8610
```

Gambar 1 Statistik Deskripsi Rice Dataset

Hasil analisis menunjukkan bahwa seluruh variabel numerik memiliki skala yang berbeda-beda, sehingga diperlukan proses standardisasi agar perbedaan skala tersebut tidak memengaruhi perhitungan jarak pada metode clustering yang digunakan [3].

Kelas	Jumlah Data	Persentase
Cammeo	1630	42.8%
Osmancik	2180	57.2%
Total	**3810**	**100%**

Tabel 1 Distribusi Label Asli pada Rice Dataset

Analisis distribusi kelas asli menunjukkan bahwa dataset terdiri dari dua kelas, yaitu Cammeo dengan 1.630 observasi dan Osmancik dengan 2.180 observasi. Distribusi data yang relatif tidak seimbang ini masih berada dalam batas wajar dan tidak menghalangi pelaksanaan analisis clustering [19].

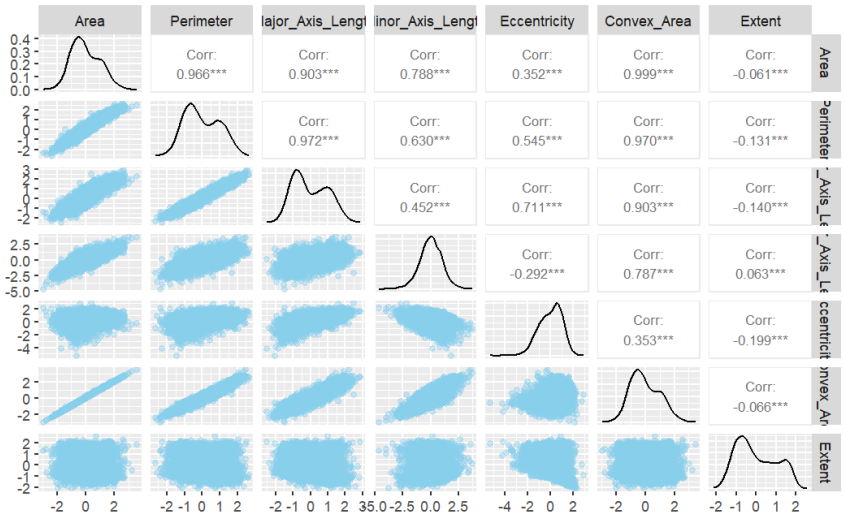

Gambar 2 Visualisasi Awal Data

Visualisasi awal menggunakan *scatter plot matrix* (*pair plot*) dilakukan untuk melihat hubungan antar variabel numerik dalam dataset. Hasil visualisasi menunjukkan bahwa sebagian besar variabel, seperti *Area*, *Perimeter*, *Major Axis Length*, dan *Convex Area*, memiliki korelasi positif yang kuat ditandai dengan pola titik yang cenderung membentuk garis linier, sehingga mengindikasikan adanya redundansi informasi antar fitur tersebut. Sebaliknya, variabel *Extent* menunjukkan korelasi yang relatif lemah terhadap variabel lainnya, sehingga kontribusinya dalam membedakan cluster diperkirakan tidak terlalu signifikan. Secara keseluruhan, data memiliki struktur yang cukup jelas dan terorganisir, sehingga layak untuk dianalisis lebih lanjut menggunakan metode *clustering*.

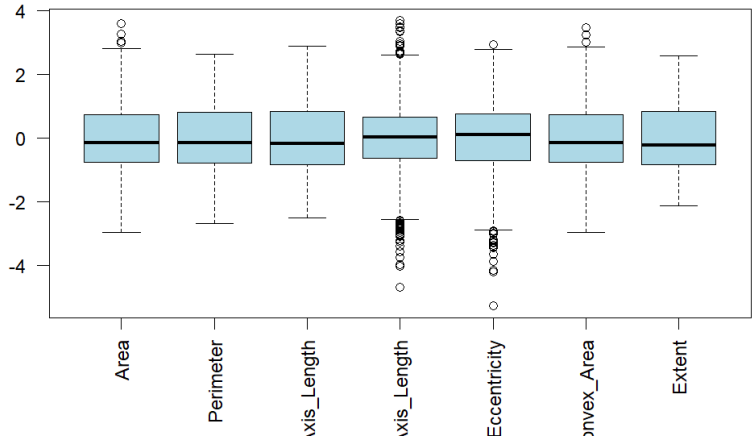

Gambar 3 Boxplot Data Standarisasi

Deteksi outlier dilakukan menggunakan *boxplot* pada data yang telah distandarisasi. Hasil visualisasi menunjukkan adanya beberapa outlier pada sejumlah variabel, namun tidak

dalam jumlah yang signifikan. Oleh karena itu, data tetap digunakan secara keseluruhan tanpa penghapusan outlier, dengan pertimbangan bahwa metode clustering yang diterapkan, khususnya DBSCAN yang mampu menangani keberadaan data ekstrem tersebut [11].

4.2 Preprocessing Data

Tahap *preprocessing* dilakukan melalui beberapa langkah untuk memastikan kualitas data sebelum analisis clustering dilaksanakan.

```
          Area         Perimeter Major_Axis_Length Minor_Axis_Length      Eccentricity
             0                 0                 0                 0                 0
    Convex_Area            Extent             Class
             0                 0                 0
```

Gambar 4 Pemeriksaan Missing Value Pada Data

Pertama, dilakukan pengecekan *missing value* pada seluruh variabel dalam dataset. Hasil pemeriksaan menunjukkan bahwa tidak terdapat nilai yang hilang pada seluruh variabel, sehingga tidak diperlukan proses imputasi maupun penanganan khusus terhadap data yang tidak lengkap.

```
```{r}
sum(duplicated(data))
```
```

```
[1] 0
```

Gambar 5 Pemeriksaan Data Duplikat

Kedua, dilakukan pengecekan data duplikasi. Hasil analisis menunjukkan bahwa tidak ditemukan adanya observasi yang terduplikasi dalam dataset, sehingga seluruh data bersifat unik dan dapat langsung digunakan dalam proses analisis.

```
# Mean harus ~0
colMeans(data_scaled)

# SD harus ~1
apply(data_scaled, 2, sd)
```

```
             Area         Perimeter Major_Axis_Length Minor_Axis_Length      Eccentricity
     4.302661e-17      5.627370e-16      6.691625e-16     -2.357425e-16     -2.092311e-15
      Convex_Area            Extent
    -4.608432e-16      2.394287e-16
             Area         Perimeter Major_Axis_Length Minor_Axis_Length      Eccentricity
                1                 1                 1                 1                 1
      Convex_Area            Extent
                1                 1
```

Gambar 6 Hasil Standarisasi Data

Ketiga, dilakukan standardisasi data menggunakan metode *Z-score normalization* untuk menyeragamkan skala antar variabel, mengingat setiap fitur memiliki rentang nilai yang

berbeda-beda [3][7]. Hasil standardisasi menunjukkan bahwa setiap variabel memiliki nilai rata-rata mendekati nol dan standar deviasi mendekati satu. Dengan demikian, seluruh variabel telah berada pada skala yang seragam sehingga metode *clustering* berbasis jarak dapat bekerja secara optimal tanpa bias akibat perbedaan skala antar variabel.

4.3 Hasil Clustering K-Means

4.3.1 K-Means (k=3)

Cluster	Jumlah Data
1	1509
2	1249
3	1052
Total	**3810**

Tabel 2 Distribusi Hasil Clustering K-Means (k = 3)

Penerapan metode K-Means dengan jumlah cluster sebanyak 3 menghasilkan distribusi data sebagai berikut cluster 1 sebanyak 1.509 data, cluster 2 sebanyak 1.249 data, dan cluster 3 sebanyak 1.052 data. Pembagian ini menunjukkan bahwa data terbagi ke dalam tiga kelompok dengan ukuran yang relatif seimbang.

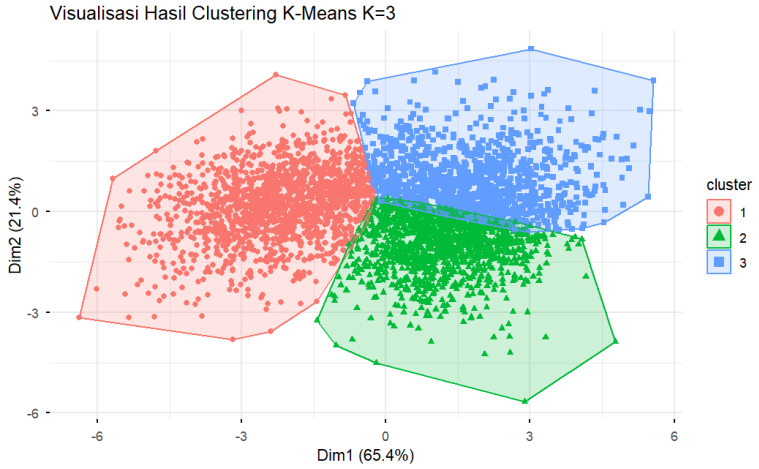

Gambar 7 Visualisasi Hasil Clustering K-Means (k = 3)

Berdasarkan hasil visualisasi, pembentukan tiga cluster cenderung memecah struktur alami data menjadi bagian yang lebih kecil. Meskipun terdapat pemisahan antar *cluster*, beberapa area masih menunjukkan *overlap* yang mengindikasikan bahwa batas antar *cluster* tidak sepenuhnya terbentuk secara jelas.

Evaluasi internal menggunakan *Silhouette Score* menghasilkan nilai sebesar 0.3086824,

yang menunjukkan bahwa kualitas *cluster* berada pada kategori sedang dan masih terdapat sejumlah data yang kurang tepat dalam pengelompokannya [15][16].

Cluster	Cammeo	Osmancik	Total
1	1407	102	1509
2	62	1187	1249
3	161	891	1052
Total	**1630**	**2180**	**3810**

Tabel 3 Perbandingan Hasil Clustering K-Means (k = 3) dengan Label Asli

Evaluasi eksternal dengan membandingkan hasil cluster terhadap label asli menunjukkan bahwa ketiga cluster tidak secara jelas merepresentasikan dua kelas utama (Cammeo dan Osmancik), melainkan cenderung membagi data menjadi subkelompok yang bercampur dengan proporsi kedua kelas yang bervariasi di setiap cluster [14]. Secara keseluruhan, penggunaan k = 3 kurang optimal karena memaksa data terbagi menjadi tiga kelompok, padahal secara alami data lebih cenderung membentuk dua kelompok utama [2].

4.3.2 K-Means (k=2)

Cluster	Jumlah Data
1	1576
2	2234
Total	**3810**

Tabel 4 Distribusi Hasil Clustering K-Means (k = 2)

Penerapan K-Means dengan jumlah cluster sebanyak 2 menghasilkan distribusi cluster 1 sebanyak 1.576 data dan cluster 2 sebanyak 2.234 data, menunjukkan pembagian data yang cukup proporsional.

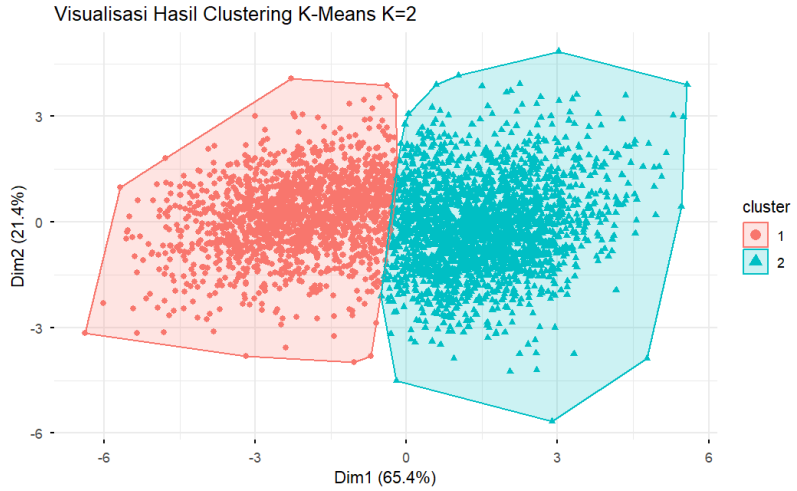

Gambar 8 Visualisasi Hasil Clustering K-Means (k = 3)

Berdasarkan nilai centroid, kedua cluster memiliki perbedaan yang cukup jelas pada sebagian besar variabel, yang mengindikasikan adanya pemisahan karakteristik antar kelompok data [1]. Visualisasi hasil clustering memperlihatkan bahwa kedua cluster terpisah lebih tegas dibandingkan dengan k = 3, meskipun masih terdapat sedikit *overlap* di area tertentu.

Evaluasi internal menggunakan *Silhouette Score* menghasilkan nilai sebesar 0.4099614, lebih tinggi dibandingkan k = 3, yang menunjukkan kualitas cluster lebih baik dengan tingkat kekompakan dan pemisahan yang lebih optimal [15].

Cluster	Cammeo	Osmancik	Total
1	1437	139	1576
2	193	2041	2234
Total	**1630**	**2180**	**3810**

Tabel 5 Perbandingan Hasil Clustering K-Means (k = 2) dengan Label Asli

Evaluasi eksternal dilakukan dengan membandingkan hasil cluster terhadap label asli, di mana cluster 1 didominasi oleh kelas Cammeo sebanyak 1.437 data dan cluster 2 didominasi oleh kelas Osmancik sebanyak 2.041 data [14]. Meskipun terdapat sejumlah kecil data yang tertukar antar cluster, tingkat kesesuaian dengan label asli secara keseluruhan cukup tinggi.

Dengan demikian, K-Means dengan k = 2 lebih optimal dalam merepresentasikan struktur data karena menghasilkan cluster yang lebih jelas, kompak, dan sesuai dengan pola alami data dibandingkan k = 3 [2].

4.4 Hasil Clustering Hierarchical Clustering

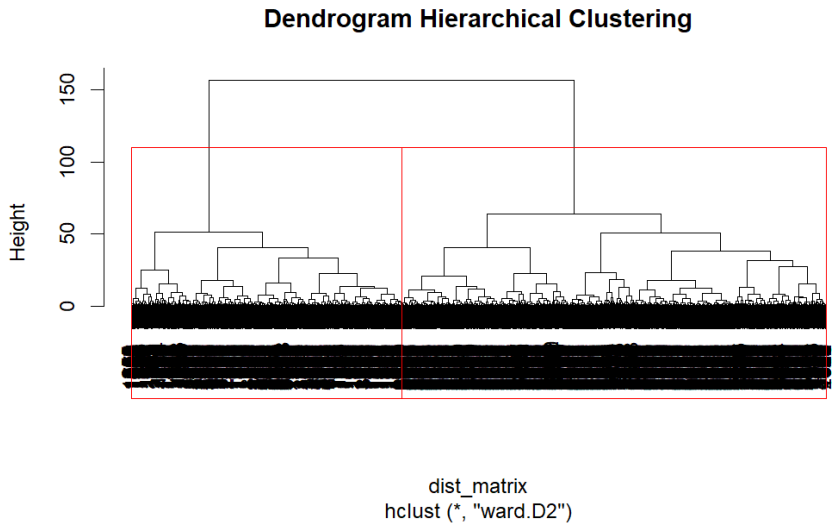

Gambar 9 Dendrogram Hierarchical Clustering pada Rice Dataset

Cluster	Jumlah Data
1	1483
2	2327
Total	**3810**

Tabel 6 Distribusi Hasil Hierarchical Clustering (k = 2)

Penerapan metode Hierarchical Clustering dengan pendekatan *agglomerative* dan metode *ward.D2* menghasilkan dua cluster yang dianggap optimal berdasarkan struktur dendrogram [6]. Distribusi data menunjukkan bahwa cluster 1 terdiri dari 1.483 observasi dan cluster 2 sebanyak 2.327 observasi.

Evaluasi internal menggunakan *Silhouette Score* menghasilkan nilai sebesar 0.3954606, yang menunjukkan kualitas cluster tergolong cukup baik meskipun belum mencapai tingkat optimal [15]. Nilai ini mengindikasikan bahwa pemisahan antar cluster sudah cukup jelas, namun masih terdapat beberapa data yang berada di area perbatasan antar cluster.

Cluster	Cammeo	Osmancik	Total
1	1356	127	1483
2	274	2053	2327
Total	**1630**	**2180**	**3810**

Tabel 7 Perbandingan Hierarchical Clustering dengan Label Asli

Evaluasi eksternal menunjukkan bahwa cluster 1 didominasi oleh kelas Cammeo sebanyak 1.356 data, sedangkan cluster 2 didominasi oleh kelas Osmancik sebanyak 2.053 data [14]. Meskipun demikian, masih terdapat sejumlah data yang tertukar antar cluster, yang mengindikasikan adanya *overlap* pada karakteristik kedua kelas tersebut.

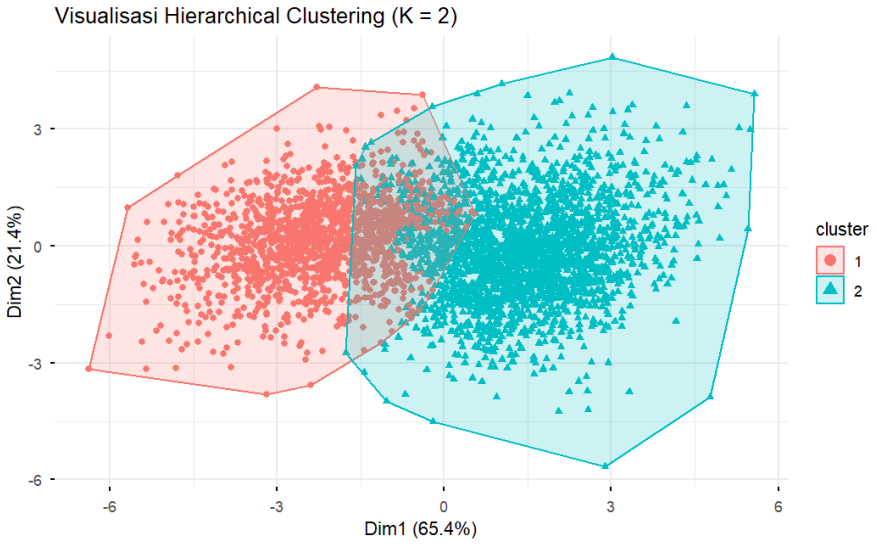

Gambar 10 Visualisasi Hasil Hierarchical Clustering

Hasil visualisasi memperlihatkan bahwa kedua cluster telah terpisah dengan cukup jelas pada dimensi utama data, namun dibandingkan dengan K-Means, batas antar cluster terlihat kurang tegas dengan *overlap* yang lebih besar pada area tertentu [7]. Secara keseluruhan, metode Hierarchical Clustering mampu menangkap struktur utama data dengan cukup baik, namun performanya masih sedikit di bawah K-Means (k = 2) baik dari segi nilai *Silhouette Score* maupun kejelasan pemisahan cluster [16].

4.5 Hasil DBSCAN

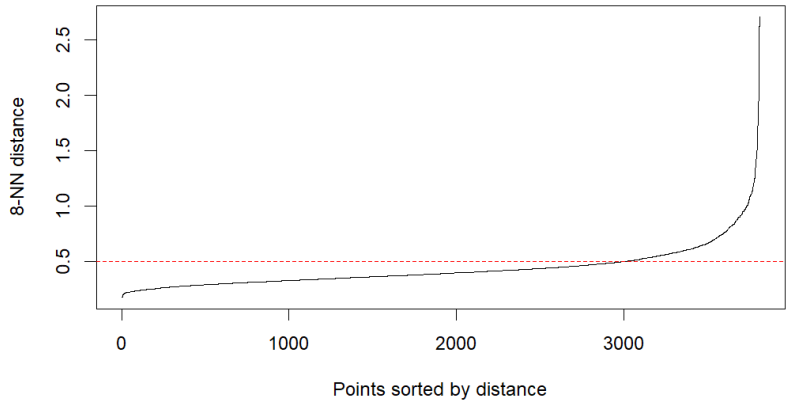

Gambar 11K-Nearest Neighbor Distance Plot untuk Penentuan Nilai Epsilon (ε) pada DBSCAN

Penentuan parameter DBSCAN dilakukan melalui analisis grafik *k-nearest neighbor distance plot* untuk memperoleh nilai epsilon (ε) yang optimal [10]. Berdasarkan visualisasi tersebut, nilai ε ditetapkan sebesar 0,8 dengan *minimum points* (MinPts) sebesar 8, karena pada titik tersebut mulai terlihat perubahan kemiringan kurva yang menandakan batas kepadatan optimal antar data [11].

Cluster	Jumlah Data
0 (*Noise*)	56
1	3754
Total	**3810**

Gambar 12 Distribusi Hasil Clustering DBSCAN

Hasil clustering menunjukkan bahwa DBSCAN hanya membentuk 1 cluster utama dengan 3.754 data, serta mengidentifikasi 56 data sebagai noise. Kondisi ini mengindikasikan bahwa sebagian besar data dianggap berada dalam satu wilayah padat yang sama, sehingga

DBSCAN tidak mampu memisahkan data ke dalam beberapa cluster yang berbeda secara jelas. Meskipun keberadaan noise menunjukkan kemampuan DBSCAN dalam mendeteksi data yang menyimpang dari pola umum, hasil clustering yang hanya membentuk satu cluster menjadi kurang informatif untuk kebutuhan segmentasi data [11]. Hal ini mengindikasikan bahwa struktur data pada dataset ini cenderung terlalu rapat dan homogen untuk dipisahkan secara efektif menggunakan pendekatan berbasis kepadatan.

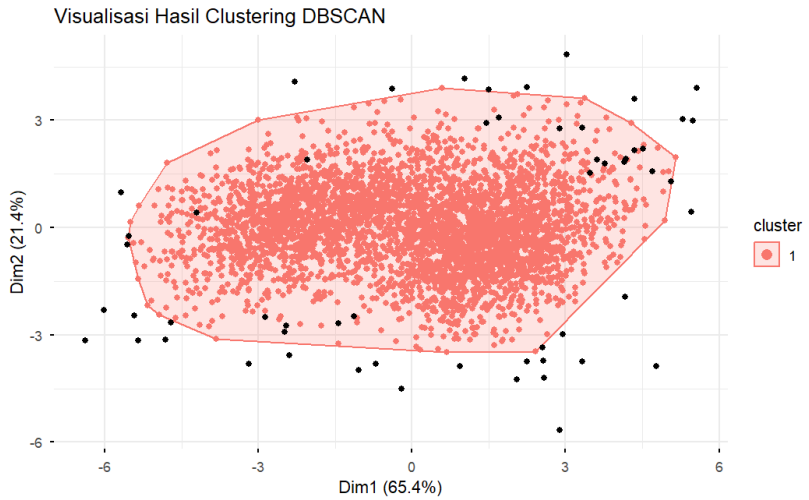

Gambar 13 Visualisasi Hasil DBSCAN

Visualisasi hasil DBSCAN memperlihatkan bahwa metode ini belum mampu memisahkan data ke dalam beberapa cluster yang jelas, di mana sebagian besar observasi tergabung dalam satu cluster utama dan hanya sejumlah kecil data teridentifikasi sebagai noise [11]. Kondisi ini mengindikasikan bahwa struktur data memiliki kepadatan yang relatif homogen, sehingga DBSCAN kesulitan menemukan perbedaan kepadatan yang cukup signifikan untuk membentuk cluster yang terpisah.

Evaluasi menggunakan *Silhouette Score* tidak dapat dilakukan secara valid pada hasil DBSCAN ini, karena metrik tersebut memerlukan minimal dua cluster untuk menghitung jarak *intra-cluster* dan *inter-cluster* [15][16]. Oleh karena itu, nilai *Silhouette Score* untuk DBSCAN dinyatakan tidak tersedia (NA).

Secara keseluruhan, metode DBSCAN kurang sesuai untuk diterapkan pada dataset ini. Meskipun mampu mendeteksi noise, DBSCAN gagal membentuk pemisahan cluster yang representatif, sehingga pendekatan berbasis kepadatan dinilai tidak cukup efektif untuk menangkap struktur data pada *Rice Dataset* yang cenderung lebih sesuai dianalisis menggunakan metode berbasis partisi seperti K-Means [18].

4.6 Hasil Fuzzy C-Means

Cluster	Jumlah Data
1	2199
2	1611
Total	**3810**

Tabel 8 Distribusi Hasil Clustering Fuzzy C-Means

Penerapan metode Fuzzy C-Means dengan jumlah cluster sebanyak 2 menghasilkan distribusi cluster 1 sebanyak 2.199 data dan cluster 2 sebanyak 1.611 data, menunjukkan pembagian data ke dalam dua kelompok utama dengan proporsi yang relatif seimbang.

Berbeda dengan metode *hard clustering*, Fuzzy C-Means menghasilkan nilai *membership* yang merepresentasikan derajat keanggotaan setiap data terhadap masing-masing cluster [12]. Hasil *membership* menunjukkan bahwa sebagian besar data memiliki tingkat keanggotaan yang tinggi pada salah satu cluster, sehingga meskipun pendekatannya bersifat *fuzzy*, pemisahan data tetap cukup jelas. Hal ini mengindikasikan bahwa mayoritas observasi memiliki kecenderungan kuat untuk berada pada satu cluster tertentu, sementara sebagian kecil lainnya berada pada area transisi antar cluster [13].

Evaluasi internal menggunakan *Silhouette Score* menghasilkan nilai sebesar 0.4087643, yang menunjukkan kualitas *clustering* tergolong baik dan sangat mendekati performa K-Means (k = 2) [15].

Cluster	Cammeo	Osmancik	Total
1	175	2024	2199
2	1455	156	1611
Total	**1630**	**2180**	**3810**

Tabel 9 Perbandingan Hasil Clustering Fuzzy C-Means dengan Label Asli

Evaluasi eksternal menunjukkan bahwa cluster 1 didominasi oleh kelas Osmancik sebanyak 2.024 data, sedangkan cluster 2 didominasi oleh kelas Cammeo sebanyak 1.455 data [14]. Meskipun masih terdapat sejumlah kecil data yang tertukar antar cluster, hasil ini menunjukkan bahwa Fuzzy C-Means mampu merepresentasikan struktur asli data dengan cukup baik.

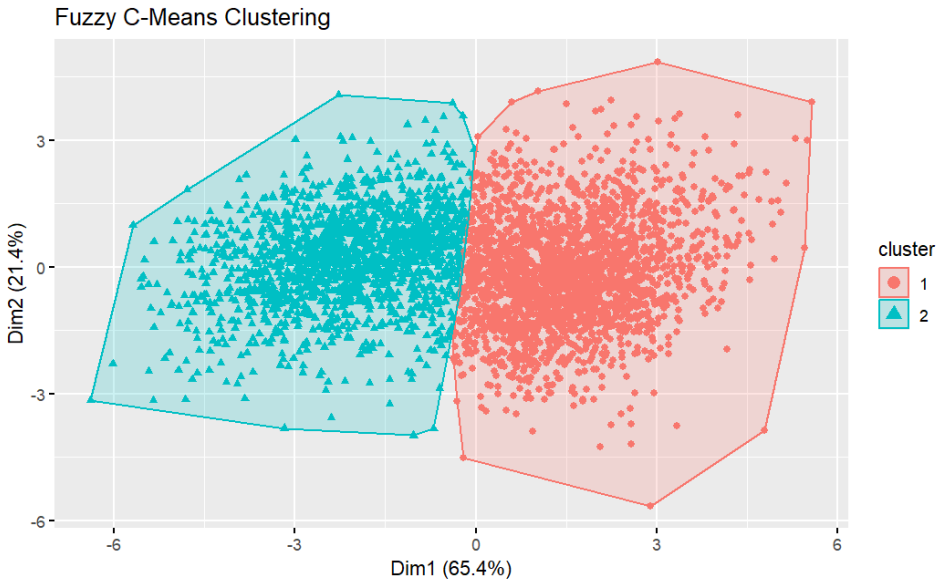

Gambar 14 Visualisasi Hasil Fuzzy C-Means

Hasil visualisasi memperlihatkan bahwa kedua cluster terpisah dengan cukup jelas, meskipun terdapat sedikit *overlap* pada area perbatasan yang sejalan dengan konsep *fuzzy clustering*, di mana suatu data dapat memiliki derajat keanggotaan pada lebih dari satu cluster sekaligus [13]. Secara keseluruhan, Fuzzy C-Means menunjukkan performa yang kompetitif dibandingkan metode lainnya dan tetap efektif dalam menangkap struktur alami data, terutama pada data yang berada di area transisi antar cluster [12].

4.7 Perbandingan Metode Clustering

Perbandingan performa antar metode clustering dilakukan menggunakan evaluasi internal berupa *Silhouette Score*, yang mengukur kualitas cluster berdasarkan tingkat kekompakan (*cohesion*) dan keterpisahan (*separation*) antar cluster [15]. Semakin tinggi nilai *Silhouette Score*, semakin baik kualitas cluster yang dihasilkan [16].

Hasil evaluasi menunjukkan bahwa K-Means dengan 2 cluster memperoleh nilai *Silhouette Score* tertinggi sebesar 0.4099614, diikuti Fuzzy C-Means sebesar 0.4087643, Hierarchical Clustering sebesar 0.3954606, dan K-Means dengan 3 cluster sebesar 0.3086824. Sementara itu, DBSCAN tidak menghasilkan nilai *Silhouette Score* karena hanya membentuk satu cluster utama [15][16]. Rekapitulasi perbandingan nilai *Silhouette Score* seluruh metode disajikan pada Tabel 10.

Metode	Jumlah Cluster	Silhouette Score
K-Means	2	0.4099614
Fuzzy C-Means	2	0.4087643
Hierarchical Clustering	2	0.3954606
K-Means	3	0. 3954606
DBSCAN	1	NA

Tabel 10 Perbandingan Nilai Silhouette Score pada Setiap Metode Clustering

Secara umum, K-Means (k = 2), Fuzzy C-Means, dan Hierarchical Clustering menunjukkan performa yang cukup baik dalam mengelompokkan data, dengan ketiganya mampu membentuk dua cluster utama yang relatif sesuai dengan struktur asli data [5]. K-Means (k = 2) menghasilkan pemisahan cluster paling optimal ditunjukkan oleh nilai *Silhouette Score* tertinggi serta hasil evaluasi eksternal yang paling mendekati distribusi label asli [14]. Sebaliknya, K-Means dengan 3 cluster menunjukkan performa lebih rendah karena memaksa data terbagi menjadi tiga kelompok yang tidak sesuai dengan struktur alaminya [2], sedangkan DBSCAN menjadi metode dengan performa paling rendah karena gagal membentuk lebih dari satu cluster yang representatif [11].

Berdasarkan keseluruhan hasil evaluasi, K-Means dengan 2 cluster ditetapkan sebagai metode terbaik untuk mengelompokkan *Rice Dataset*, karena memberikan kualitas cluster paling baik, pemisahan paling jelas, serta kesesuaian tertinggi terhadap struktur alami data [1][2].

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan hasil analisis dan perbandingan beberapa metode clustering pada *Rice (Cammeo and Osmancik) Dataset*, dapat disimpulkan bahwa data secara alami cenderung membentuk dua cluster utama, yang terlihat konsisten dari hasil eksplorasi data, visualisasi, serta evaluasi seluruh metode yang digunakan [19].

K-Means dengan 2 cluster menghasilkan performa terbaik dengan nilai *Silhouette Score* tertinggi sebesar 0, 4099614, menunjukkan bahwa metode ini mampu membentuk cluster yang paling kompak dan terpisah dengan baik serta memiliki tingkat kesesuaian tertinggi terhadap label asli data [1][2]. Fuzzy C-Means menunjukkan performa yang sangat kompetitif dengan nilai *Silhouette Score* sebesar 0,4087643, di mana keunggulan utamanya terletak pada kemampuan menangkap data yang berada pada area transisi antar cluster melalui nilai derajat keanggotaan (*membership*), sehingga memberikan interpretasi yang lebih fleksibel [12][13]. Hierarchical Clustering juga mampu mengelompokkan data dengan cukup baik meskipun performanya sedikit di bawah kedua metode tersebut [6][7]. Sementara itu, DBSCAN menjadi metode yang paling kurang sesuai pada dataset ini karena hanya membentuk satu cluster utama sehingga tidak dapat merepresentasikan struktur alami data secara optimal [11].

Secara keseluruhan, K-Means dengan 2 cluster merupakan metode terbaik untuk mengelompokkan *Rice Dataset*, sedangkan Fuzzy C-Means dapat menjadi alternatif yang baik ketika diperlukan interpretasi yang lebih fleksibel terhadap data yang memiliki *overlap* antar cluster [5].

5.2 Saran

Berdasarkan hasil analisis ini, terdapat beberapa saran untuk pengembangan analisis selanjutnya. Penelitian berikutnya dapat menggunakan dataset yang lebih besar dan beragam, dan mengeksplorasi metode clustering lain seperti *Gaussian Mixture Model* (GMM) atau *Spectral Clustering* untuk membandingkan performa pada data dengan karakteristik serupa [5]. Selain itu, evaluasi dapat diperluas dengan menambahkan metrik validasi seperti *Davies-Bouldin Index* atau *Calinski-Harabasz Index* [16], dan mengeksplorasi metode reduksi dimensi seperti *t-SNE* atau *UMAP* untuk menghasilkan visualisasi cluster yang lebih representatif.

DAFTAR PUSTAKA

[1] C. Azzahra and Sriani, "Clustering of High School Students Academic Scores Using K-Means Algorithm," *Journal of Information Systems and Informatics*, vol. 7, no. 1, pp. 572–586, 2025, doi: 10.51519/journalisi.v7i1.1029.

[2] N. A. Maori and E. Evanita, "Metode Elbow dalam Optimasi Jumlah Cluster pada K-Means Clustering," *Simetris: Jurnal Teknik Mesin, Elektro dan Ilmu Komputer*, vol. 14, no. 2, pp. 277–288, 2023, doi: 10.24176/simet.v14i2.9630.

[3] S. Juanita and R. D. Cahyono, "K-Means Clustering with Comparison of Elbow and Silhouette Methods for Medicines Clustering Based on User Reviews," *Jurnal Teknik Informatika (JUTIF)*, vol. 5, no. 1, pp. 283–289, Feb. 2024.

[4] I. Herdiana et al., "A More Precise Elbow Method for Optimum K-means Clustering," *arXiv*, preprint arXiv:2502.00851, Feb. 2025.

[5] A. Sujjada, G. P. Insany, and S. Noer, "Analisis Clustering Data Penyandang Disabilitas Menggunakan Metode Agglomerative Hierarchical Clustering dan K-Means," *Jurnal Teknologi dan Manajemen Informatika*, vol. 10, no. 1, pp. 1–12, Jun. 2024, doi: 10.26905/jtmi.v10i1.10654.

[6] R. Gustriansyah et al., "Hierarchical Clustering for Crime Rate Mapping in Indonesia," *ILKOM Jurnal Ilmiah*, vol. 14, no. 3, pp. 275–283, Dec. 2022.

[7] R. F. Sinaga, M. A. Prabukusumo, and J. Manurung, "Analisis Hierarchical Clustering untuk Segmentasi Pelanggan pada Dataset Mall Customers," *Jurnal Sistem Informasi dan Informatika*, 2025. [Online]. Available: https://jurnal.unidha.ac.id/index.php/jiska/article/view/2615.

[8] Y. Asyfani et al., "Pengelompokan Kabupaten/Kota di Jawa Tengah Berdasarkan Kepadatan Penduduk Menggunakan Metode Hierarchical Clustering," *Journal of Data Insights*, vol. 2, no. 1, pp. 1–8, 2024.

[9] M. Ester et al., "An Improved DBSCAN Method for LiDAR Data Segmentation with Automatic Eps Estimation," *PMC/NCBI*, 2019. [Online]. Available: https://ncbi.nlm.nih.gov/pmc/articles/PMC6338962.

[10] AutoSCAN Research Group, "AutoSCAN: Automatic Detection of DBSCAN Parameters and Efficient Clustering of Data in Overlapping Density Regions," *PeerJ Computer Science*, received Oct. 2023, accepted Feb. 2024. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC11042006.

[11] Y. Hasan, "Pengukuran Silhouette Score dan Davies-Bouldin Index pada Hasil Cluster K-Means dan DBSCAN," *Jurnal Informatika dan Teknik Elektro Terapan (JITET)*, vol. 6, no. 1, pp. 60–74, 2024.

[12] TeknoIS, "Penerapan Metode Fuzzy C-Means dalam Pemilihan Program Studi Mahasiswa Baru di Perguruan Tinggi," *TeknoIS: Jurnal Ilmiah Teknologi Informasi dan Sains*, 2020. [Online]. Available: https://teknois.unbin.ac.id/index.php/JBS/article/view/84.

[13] N. Setiawan et al., "Kombinasi K-Means dan Fuzzy C-Means untuk Clustering Transaksi PPOB Berdasarkan Validitas Cluster," *Jurnal Komputer Teknologi Informasi Sistem Komputer (JUKTISI)*, vol. 4, no. 3, pp. 2251–2263, 2026, doi: 10.62712/juktisi.v4i3.839.

[14] Paembonan, "Penerapan Metode Silhouette Coefficient untuk Evaluasi Clustering Obat," *PENA TEKNIK: Jurnal Ilmiah Ilmu-Ilmu Teknik*, 2021. [Online]. Available: https://ojs.unanda.ac.id/index.php/jiit/article/view/659.

[15] "Optimization of K Value in Clustering Using Silhouette Score (Case Study: Mall Customers Data)," *Journal of Information Technology and its Utilization*, vol. 6, no. 2, Dec. 2023. [Online]. Available: https://jkd.komdigi.go.id/index.php/jitu/article/view/5243.

[16] "Analisis Silhouette Coefficient pada 6 Perhitungan Jarak K-Means Clustering," ResearchGate, 2021. [Online]. Available:https://www.researchgate.net/publication/351705394.

[17] "Evaluasi Kualitas Klaster Wilayah Rawan Bencana Menggunakan K-Means dengan Silhouette dan Elbow Method," *Jurnal Algoritma*, ITG, 2025. [Online]. Available: https://jurnal.itg.ac.id/index.php/algoritma/article/view/2379.

[18] K. P. Sinaga and M. S. Yang, "Unsupervised K-Means Clustering Algorithm," *IEEE Access*, vol. 8, pp. 80716–80727, 2020, doi: 10.1109/Access.2020.2988796.

[19] UCI Machine Learning Repository, "Rice (Cammeo and Osmancik) Dataset," UC Irvine, 2019. [Online]. Available:https://archive.ics.uci.edu/dataset/545/rice+cammeo+and+osmancik. [Accessed: 01-May-2026].

LAMPIRAN

Lampiran 1. Kode Program

Kode program dapat diakses melalui link berikut:

https://rpubs.com/Afifah126/perbandingan-metode-clustering-pada-dataset-rice

http://github.com/Afifah1206/Clustering-dengan-Metode-K-Means-Hierarchical-Clustering-DBSCAN-dan-Fuzzy-C-Mean-pada-Rice-Dataset

Lampiran 2. Visualisasi

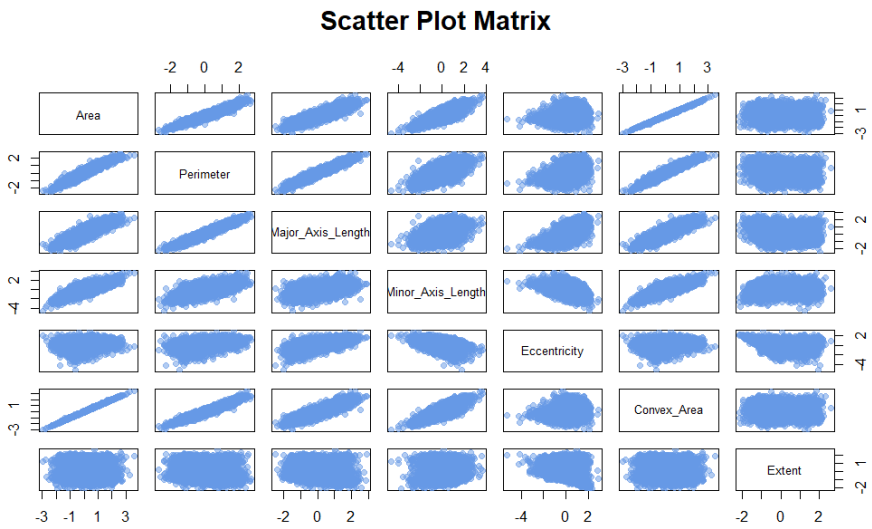

Gambar 15 Visualisasi Awal Data Standarisasi

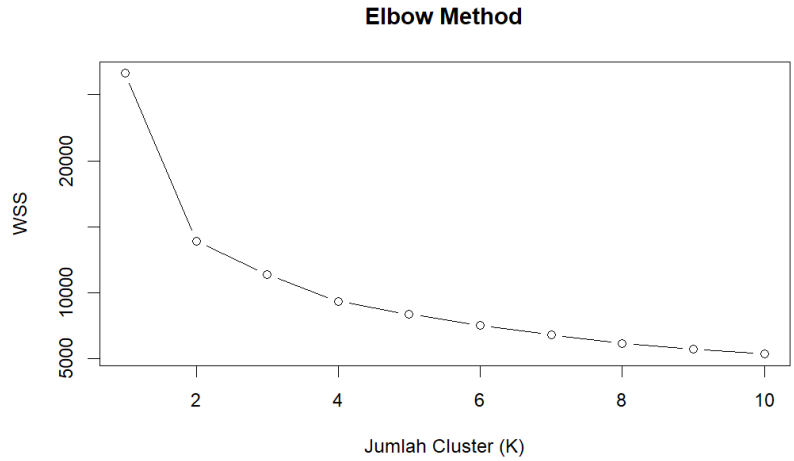

Gambar 16 Metode Elbow Methode untuk Menentukan k Optimal

Lampiran 3. Tabel

Variabel	Tipe	Deskripsi
Area	Numerik	Luas permukaan butiran beras (dalam piksel)
Perimeter	Numerik	Keliling atau panjang batas luar butiran beras
Major Axis Length	Numerik	Panjang sumbu utama (sumbu terpanjang) dari elips yang melingkupi butiran beras
Minor Axis Length	Numerik	Panjang sumbu minor (sumbu terpendek) dari elips yang melingkupi butiran beras
Eccentricity	Numerik	Tingkat kelonjongaan bentuk butiran beras (nilai 0 = lingkaran sempurna, nilai mendekati 1 = sangat lonjong)
Convex Area	Numerik	Luas area cembung (*convex hull*) yang menutupi butiran beras
Extent	Numerik	Rasio antara luas butiran beras terhadap luas kotak pembatas (*bounding box*)
Class	Kategorikal	Label jenis beras: Cammeo (1.630 data) atau Osmancik (2.180 data)

Tabel 11 Deskripsi dan Tipe Variabel Rice (Cammeo and Osmancik) Dataset

Area	Perimeter	Major Axis Length	Minor Axis Length	Eccentricity	Convex Area	Extent	Class
15231	525,579	229,750	85,094	0,9289	15617	0,5729	Cammeo
14656	494,311	206,020	91,731	0,8954	15072	0,6154	Cammeo
14634	501,122	214,107	87,768	0,9121	14954	0,6933	Cammeo
13176	458,343	193,337	87,448	0,8919	13368	0,6407	Cammeo
14688	507,167	211,743	89,312	0,9067	15262	0,6460	Cammeo
...	...	...	...	...	...	...	...
11441	415,858	170,487	85,757	0,8643	11628	0,6810	Osmancik
11625	421,390	167,715	89,463	0,8459	11904	0,6943	Osmancik
12437	442,499	183,573	86,802	0,8811	12645	0,6267	Osmancik
9882	392,297	161,194	78,210	0,8744	10097	0,6591	Osmancik
11434	404,710	161,079	90,868	0,8257	11591	0,8029	Osmancik

Tabel 12 Sampel Data Rice (Cammeo and Osmancik) Dataset